forcats

Entornos de Análisis de Datos: R

Alberto Torres Barrán

2021-01-07

Factores

- Representan variables categóricas, con un número posible de valores:
    - fijo
    - *pequeño*
    - conocido
- Ejemplos: meses del año, provincias, paises de la Unión Europea, etc.
- Muchas funciones de R convierten los vectores de cadenas de caracteres a factores automáticamente
- La librería `forcats` implementa funciones para manipular factores

Creando factores

- Función `factor()`
- Necesita dos argumentos:
  - Datos a convertir (típicamente vector de cadenas)
  - Opcionalmente también los valores posibles (**niveles**)

```
x <- c("Primavera", "Verano", "Verano", "Verano", "Otoño")
f <- factor(x, levels = c("Primavera", "Verano", "Otoño", "Invierno"))
f
## [1] Primavera Verano    Verano    Verano    Otoño
## Levels: Primavera Verano Otoño Invierno
```

- Los niveles se pueden ver con la función `levels`

```
levels(f)
## [1] "Primavera" "Verano"    "Otoño"     "Invierno"
```

- Si un valor no está en los niveles se convierte a `NA`

```
x <- c("Primavera", "Verano", "Verano", "Verano", "Otono")
f1 <- factor(x, levels = c("Primavera", "Verano", "Otoño", "Invierno"))
f1
## [1] Primavera Verano    Verano    Verano    <NA>
## Levels: Primavera Verano Otoño Invierno
```

- Si no se indican los niveles, se toman como los valores únicos del vector

```
unique(x)
## [1] "Primavera" "Verano"    "Otono"
```

```
factor(x)
## [1] Primavera Verano    Verano    Verano    Otono
## Levels: Otono Primavera Verano
```

Orden de los niveles

- Por defecto los niveles están en orden creciente:

```
sort(unique(x))
## [1] "Otono"     "Primavera" "Verano"
```

- En la mayoría de los casos el orden de los factores es irrelevante
- Dos ejemplos donde importa el orden:
    1. realizar gráficos, el orden de las escalas es el orden de los niveles del factor
    2. realizar modelos, donde el primer nivel se considera el nivel de referencia

Función cut

- Crea un factor a partir de una variable numérica

```
edad <- c(10, 15, 20, 25, 38)
cut(edad, breaks = c(10, 20, 30, 40))
## [1] <NA>    (10,20] (10,20] (20,30] (30,40]
## Levels: (10,20] (20,30] (30,40]
```

- Incluir el valor de la izquierda del primer intervalo

```
cut(edad, breaks = c(10, 20, 30, 40), include.lowest = TRUE)
## [1] [10,20] [10,20] [10,20] (20,30] (30,40]
## Levels: [10,20] (20,30] (30,40]
```

- Cerrar los intervalos por la izquierda, no la derecha

```
cut(edad, breaks = c(10, 20, 30, 40), right = FALSE)
## [1] [10,20) [10,20) [20,30) [20,30) [30,40)
## Levels: [10,20) [20,30) [30,40)
```

- Cambiar nombre de los niveles

```
cut(edad, breaks = c(10, 20, 30, 40), labels = c("10-20", "20-30", "30-40"))
## [1] <NA>  10-20 10-20 20-30 30-40
## Levels: 10-20 20-30 30-40
```

Creación factor de ejemplo

- Creamos un factor de ejemplo con los tipos de coche de `mpg`

```
f <- factor(mpg$class)
length(f)
## [1] 234
```

- Niveles:

```
levels(f)
## [1] "2seater"    "compact"    "midsize"    "minivan"    "pickup"     "subc
```

- Frecuencia de cada uno de los niveles

```
fct_count(f) %>% arrange(desc(n))
## # A tibble: 7 x 2
##   f              n
##   <fct>      <int>
## 1 suv           62
## 2 compact       47
## 3 midsize       41
## 4 subcompact    35
## 5 pickup        33
## 6 minivan       11
## 7 2seater        5
```

Reordenar niveles de un factor

- `fct_relevel()`, para reordenar los niveles a mano (se mueven al principio)

```
f1 <- fct_relevel(f, "minivan", "compact")
levels(f1)
## [1] "minivan"    "compact"    "2seater"    "midsize"    "pickup"     "subc
```

- `fct_infreq()`, para reordenar los niveles de acuerdo a su frecuencia

```
f2 <- fct_infreq(f)
levels(f2)
## [1] "suv"        "compact"    "midsize"    "subcompact" "pickup"     "mini
```

Reordenar de acuerdo a otra variable

- `fct_reorder()`, para reordenar los niveles de acuerdo a otra variable

```
f3 <- fct_reorder(f, .x = mpg$cty, .fun = mean)
levels(f3)
## [1] "pickup"     "suv"        "2seater"    "minivan"    "midsize"    "compa
```

- El orden de los niveles es creciente en `.fun(.x)`

```
consumo_medio <-
  mpg %>%
    group_by(class) %>%
    summarize(avg_cty = mean(cty))

arrange(consumo_medio, avg_cty)
## # A tibble: 7 x 2
##   class      avg_cty
##   <chr>        <dbl>
## 1 pickup        13
## 2 suv           13.5
## 3 2seater       15.4
## 4 minivan       15.8
## 5 midsize       18.8
## 6 compact       20.1
## 7 subcompact    20.4
```

La función `fct_reorder` es útil para ordenar los ejes en gráficos

```
ggplot(consumo_medio, aes(x = class, y = avg_cty)) + geom_col()
```

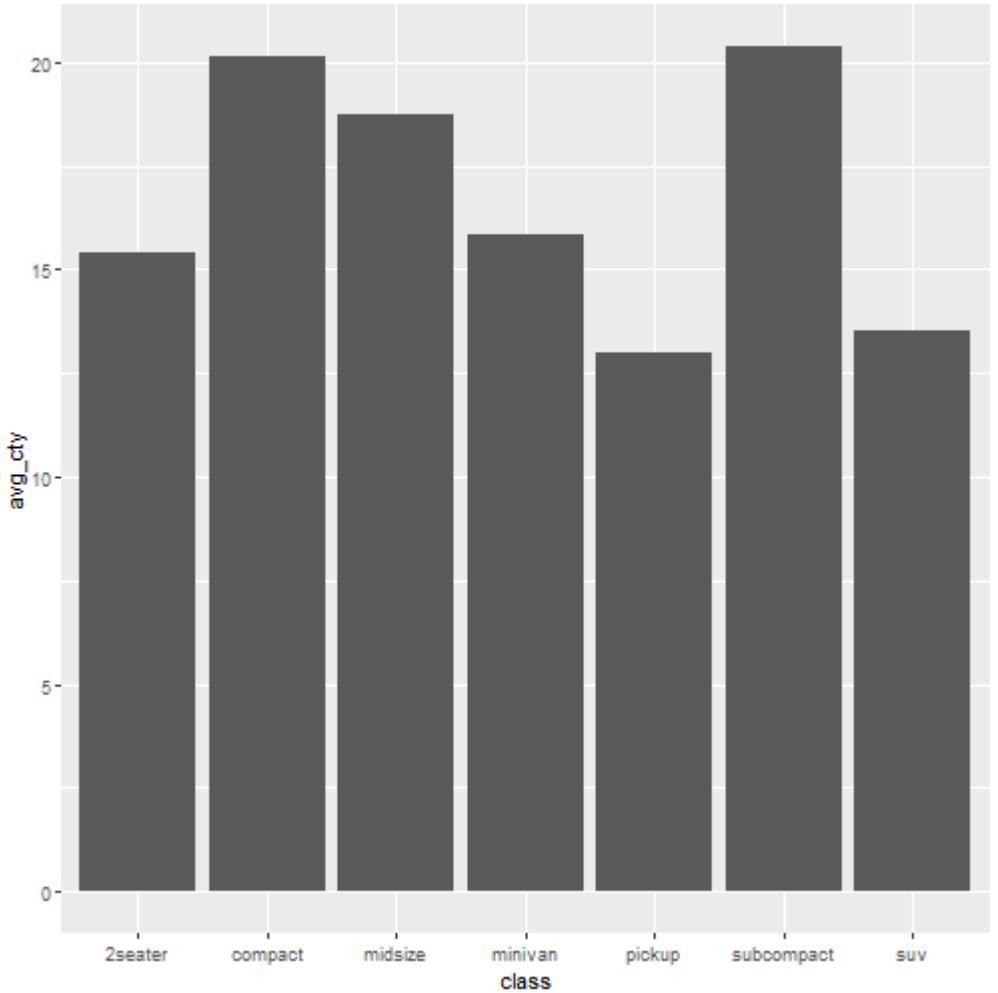

```
ggplot(consumo_medio, aes(x = fct_reorder(class, avg_cty), y = avg_cty)) +
  geom_col() +
  xlab("class")
```

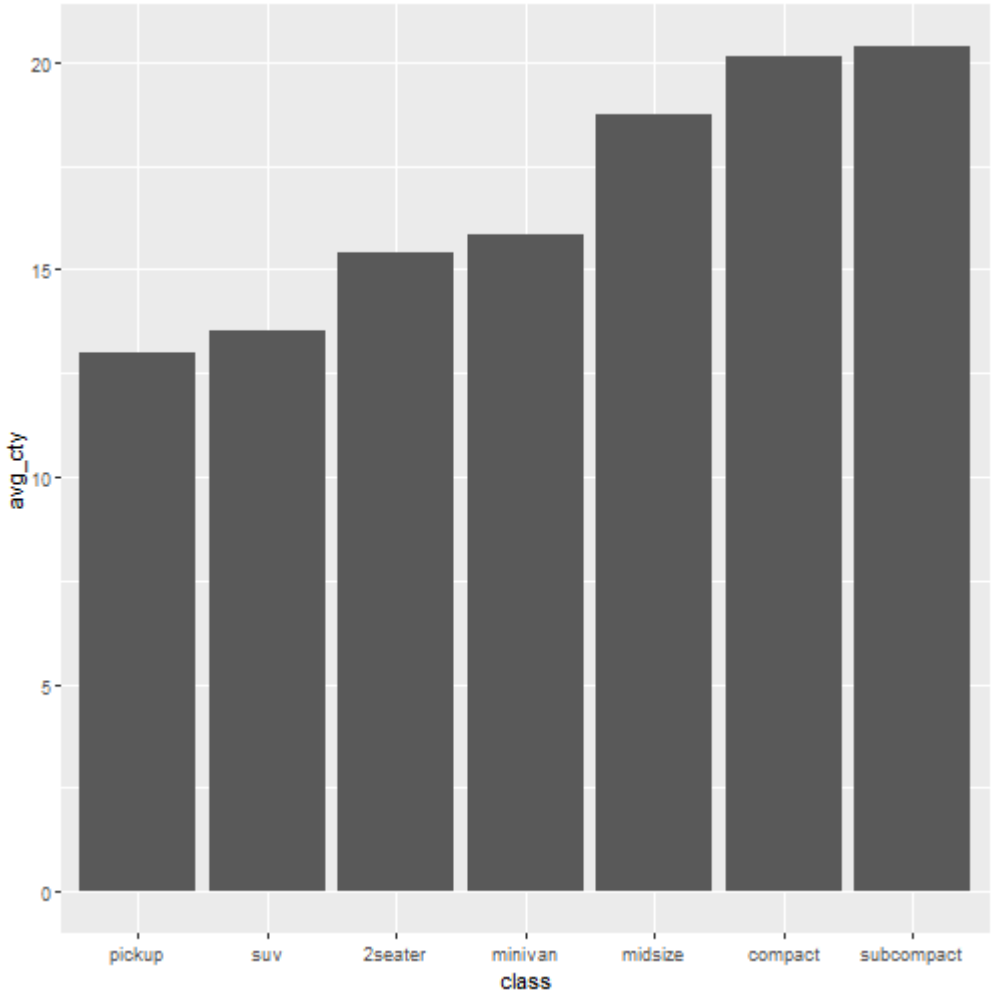

Renombrar niveles

- `fct_recode()` cambia el nombre de los niveles o los elimina (asignando el valor `NULL`)

```
f4 <- fct_recode(f, todoterreno = "suv", `2plazas` = "2seater",
                 NULL = "pickup")
levels(f4)
## [1] "2plazas"     "compact"     "midsize"     "minivan"     "subcompact"
```

- `fct_recode()` también puede colapsar niveles asignando el mismo nombre

```
f5 <- fct_recode(f, `4seater` = "compact", `4seater` = "subcompact",
                 `4seater` = "midsize")
levels(f5)
## [1] "2seater" "4seater" "minivan" "pickup"  "suv"
```

Otras funciones

- Otra alternativa es `fct_collapse`

```
f6 <- fct_collapse(f, `4seater` = c("compact", "subcompact", "midsize"),
                      `2seater` = c("2seater",   "pickup"))
levels(f6)
## [1] "2seater" "4seater" "minivan" "suv"
```

- O `fct_lump`, que colapsa los niveles menos frecuentes

```
fct_count(f) %>% arrange(desc(n))
## # A tibble: 7 x 2
##   f              n
##   <fct>      <int>
## 1 suv           62
## 2 compact       47
## 3 midsize       41
## 4 subcompact    35
## 5 pickup        33
## 6 minivan       11
## 7 2seater        5
```

```
f7 <- fct_lump(f, n = 3)
levels(f7)
## [1] "compact" "midsize" "suv"     "Other"
```